

TECHNICAL WHITEPAPER

AI 秘書「ティナ」

技術仕様・アーキテクチャ設計書

構成・設計判断・実装上の工夫

株式会社 IKKI

Technical Whitepaper

エグゼクティブサマリー

AI 秘書ティナは、既存の「フルパッケージ型アバターサービス」(HeyGen LiveAvatar、Tavus、Anam 等)に頼らず、複数の専門特化サービスを自社で組み合わせて構築した対話型 AI アバターです。単体プラットフォームの固定費に依存せず、必要な機能だけを組み合わせる構成にすることで、コスト効率と技術的な柔軟性を両立しています。

本書は、その技術構成・設計判断の背景・実装上のノウハウを整理したものです。

1. なぜ「組み合わせ型」を選んだか

HeyGen LiveAvatar や Tavus 等の統合プラットフォームは、STT(音声認識)・LLM(会話生成)・TTS(音声合成)・アバター描画までを一体提供します。導入は容易ですが、以下の制約があります。

- 固定費が発生し、同時接続数に応じてさらに費用が加算される仕組みが一般的
- 日本語の発音精度・レイテンシーを個別にチューニングする自由度が低い
- 会話ロジック(System Prompt 設計)の柔軟性が、プラットフォームの制約を受ける

これに対し、IKKI では「役割ごとに最適なサービスを選び、自社のロジックで接続する」アプローチを採用しました。

2026 年 8 月、HeyGen が Cartesia との統合を発表。業界最大手が採用するほど、Cartesia の音声品質は評価されている。IKKI は先んじてこの技術を自社構成に組み込んでいます。

2. システムアーキテクチャ

層	サービス	役割	選定理由
会話理解・生成	ElevenLabs Conversational AI	音声認識(STT)・LLM による応答生成・Knowledge Base 参照	エージェント基盤として成熟しており、Knowledge Base 機能が強力
音声合成	Cartesia (sonic-turbo)	日本語テキストの音声化。WebSocket ストリーミングで低遅延化	日本語の促音・固有名詞の発音精度が高く、低レイテンシー
映像生成	Simli	音声からリアルタイムのリップシンク映像を生成	従量課金型で、素の SDK による安定動作
データ基盤	Supabase	会話履歴・訪問者 ID・レート制限データの保存	PostgreSQL ベースで RLS(行レベルセキュリティ)に対応
ホスティング	Netlify	Next.js SPA のビルド・配信	Server Actions により、API キ

		Server Actions 実行	ーをクライアントに一切露出させない設計が可能
--	--	-------------------	------------------------

会話フロー

1. 訪問者の発話 → ElevenLabs WebSocket へ音声ストリーム送信
2. ElevenLabs が STT+LLM で応答テキストを生成(agent_response イベント)
3. 応答テキストを Cartesia の WebSocket へ送信、音声チャンクをストリーミング受信
4. 音声チャンクを Simli へ逐次送信し、リップシンク映像を生成
5. 生成された映像を LiveKit 経由でブラウザへリアルタイム配信

3. 主要な技術的課題と解決策

3.1 日本語音声品質の確保

初期構成では ElevenLabs 自体の TTS を使用していたが、日本語の促音(「っ」)や固有名詞の発音精度が実用レベルに達しなかった。Cartesia の WebSocket TTS に音声合成部分だけを差し替えることで解決。あわせて、表示テキストと音声合成用テキストを分離する仕組み(toSpeechText 関数)を実装し、「IKKI→イッキ」「三浦命助→みうらめいすけ」等、個別の読み方を随時チューニング可能な設計とした。

3.2 レイテンシーの最適化

素朴な実装では「音声の完全な生成を待ってから送信」となり、体感速度が大きく低下する。以下の対策を積み重ねて改善した。

- Cartesia を REST API から WebSocket ストリーミング API へ変更(生成中の音声チャンクを即座に送信)
- ElevenLabs ・ Cartesia ・ Simli の 3 接続を、Simli の映像準備完了を待たずに並列初期化
- Cartesia のボイス ID をセッション開始時にキャッシュし、発話ごとのサーバー往復を削減
- マイク入力の音量ベースの独自フィルタリングを撤廃し、ElevenLabs 本体の VAD(音声区間検出)に一本化(誤検知による遅延を解消)

結果として、発言終了から応答音声再生開始までの体感速度を、初期実装から半分以下まで短縮した。

3.3 二重音声・割り込み処理

ユーザーが会話中に次の質問をした場合、前の応答の音声送信が完了しないまま新しい応答の送信が始まり、二重に音声再生される不具合が発生した。「有効な応答 ID」をインクリメント管理する仕組みを実装し、古い応答の音声送信ループを新しい応答・割り込み発生時に即座に打ち切ることで解決した。

3.4 ページ連携(埋め込み時のコンテキスト共有)

ティナは対象サイトに iframe として埋め込まれる。iframe 自身の URL ではなく、実際に訪問者が見ている親ページの情報を扱う必要があるため、postMessage による親子ウィンドウ間の通信を実装した。

- ページ情報の取得:iframe→親ページへリクエスト、親ページがタイトル・URL を返信
- ページ遷移の実行:同一ページ内アンカーは親ページ側でそのまま遷移(会話を切断しない)、別ページへのリンクは新しいタブで開く(会話を継続させる)
- 訪問者 ID の発行・保持:第一者(親ページ)の localStorage で発行することで、Safari 等のサードパーティ Cookie 制限を回避

4. セキュリティ・悪用防止

- API キーはすべて Next.js Server Actions を介してサーバー側のみで使用。ブラウザには一切露出しない
- Cartesia は本キーではなく、5 分間のみ有効な一時アクセストークンをクライアントに発行
- Supabase の全テーブルで RLS(行レベルセキュリティ)を有効化し、service_role key を持つサーバー以外からのアクセスを遮断
- 利用状況を継続的に監視し、短時間の過剰なアクセスを自動的に検知・制限する仕組みを実装
- Server Action 内で例外を throw すると、本番環境ではエラーメッセージが Next.js により自動的に隠蔽される仕様のため、エラーは戻り値(success/message のオブジェクト)として返す設計に統一し、ユーザーへの案内文が確実に届くようにした
- 管理画面はパスワード認証+ログイン試行回数制限による多層防御

5. 運用上の留意点(Simli 同時接続数)

Simli の契約プランによっては、同時接続数に上限が設けられている。ブラウザの多重クリックや、タブを閉じる際の後処理未実行により、セッションが解放されないまま残留し、それ以上接続できなくなる事象が確認された。対策として、以下を実装済み。

- 開始ボタンの二重クリック防止(処理中・会話中は再度の開始処理を無視)
- ブラウザの beforeunload / pagehide イベントを検知し、タブが閉じられる瞬間に確実に全接続をクローズ

本番運用の想定同時接続数によっては、上位プランへの切り替えを検討する必要がある。

6. 今後の拡張構想

- 訪問者データと Salesforce のリード/取引先責任者オブジェクトとの自動連携
- 会話内容に基づくスコアリング・営業担当者への自動アラート

- カスタムアバター(顧客企業のご担当者ご本人の顔・声)への対応
- 複数言語対応(英語・中国語等)